

PROCESSO SELETIVO · TIME DE DADOS

CASE TÉCNICO · ANALISTA DE DADOS

Do dado cru à recomendação de *negócio*.

Salutar Saúde — Plataforma & corretora de saúde. Uma jornada de engenharia, análise e decisão sobre sinistralidade e utilização.

APRESENTADO POR

Luan Veloso Rossini

DATA DE APRESENTAÇÃO

08/07/2026

A jornada em 4 partes



1 · ENGENHARIA & MODELAGEM

A camada Gold

Camada Gold, versão oficial dos números



2 · ANÁLISE & INSIGHTS

Onde o time deve atuar

Análise dos dados, entendimento do problema e exploratória do que o time de Negócios deve focar.



3 · DASHBOARD & STORYTELLING

Comunicando ao negócio

Narrativa negocial da análise e oportunidades a ser exploradas pelo business.



4 · IA NO DIA A DIA

Uso de IA

Relatório de utilização de IA durante a execução do Case.

O contexto e os dados crus (RAW / bronze)

A Salutar Saúde ajuda empresas a contratar e gerir planos de saúde. O time de Dados usa esses dados para entender beneficiários, controlar sinistralidade e orientar onde atuar. Recebi 7 arquivos RAW — como chegam dos sistemas de origem.



Suposição-chave

- "Hoje" = 30/06/2025 — âncora de todas as janelas (últimos 12m, próximos 30d).
- RAW é imutável: nunca sobrescrevo a origem; trato tudo na transformação.
- Priorizo poucas coisas bem-feitas e explico o que faria com mais tempo.

Arquivo RAW	O que é	Grão
raw_operadoras	Operadoras de saúde	1 / operadora
raw_planos	Produtos / planos	1 / plano
raw_corretores	Corretores / executivos	1 / corretor
raw_empresas	Empresas clientes	1 / empresa
raw_contratos	Vendas (apólices)	1 / contrato
raw_beneficiarios	Vidas cobertas	1 / beneficiário
raw_utilizacao	Eventos / sinistros	1 / evento


1

PARTE 1 · ENGENHARIA & MODELAGEM

A camada Gold

Transformar dados crus numa camada confiável, modelada e reutilizável pelo negócio — o trabalho lado a lado com os engenheiros de dados.

Star schema: 3 fatos, 6 dimensões



--- dim_data / dim_empresa — dimensões conformadas (ligam vários fatos)

Por que 3 fatos? Grãos distintos (contrato · evento · empresa-mês) e aditividade distinta. fat_sinistralidade é pré-agregado para consumo direto no BI. dim_data conformada evita colunas-FK repetidas e liga vendas × utilização × sinistralidade.

Investigar, tratar e documentar a qualidade



Problemas de qualidade encontrados e regras aplicadas

Categorias despadronizadas	'Ativo' / 'ativo' / 'ATIVO' / 'Ativo '	→ trim + upper + mapa canônico
UF inconsistente	'SP' vs 'São Paulo'	→ lookup UF → sigla padrão
Sexo heterogêneo	'M' / 'Masculino' / vazio	→ normaliza p/ {M,F,NA}
Datas / moeda BR	'30/06/2025', 'R\$ 1.234,56'	→ cast explícito, locale pt-BR
Duplicidade de chave	empresa_id=8, contrato_id	→ dedup por window row_number()

```
# silver: padronização declarativa (PySpark)
df_silver = (df_raw
    .withColumn('status',
        F.upper(F.trim('status')))
    .replace(STATUS_MAP, subset=['status'])
    .withColumn('uf', map_uf('uf'))
    .withColumn('valor',
        to_number_brl('valor'))
    .dropDuplicates(['beneficiario_id']))

# regra documentada, não adivinhada:
# reporto no README o que assumi
```

Sinistralidade mensal por empresa

A métrica mais importante do negócio

sinistralidade = **custo dos sinistros ÷ receita de prêmios**

Exposta na Gold como gold_fat_sinistralidade — pronta para o negócio consumir no BI, sem recálculo.

Premissas de cálculo (explícitas)

- Janela: mês-calendário; data base = 30/06/2025.
- Receita: soma do prêmio mensal dos contratos ativos no mês (pró-rata p/ contratos parciais).
- Sinistro: soma do custo dos eventos com data no mês.
- Contratos parciais: rateio por dias de vigência no mês.
- Meses sem receita → sinistralidade nula/flag (evita divisão por zero).

```
-- gold_fat_sinistralidade
SELECT empresa_id,
       date_trunc('month', ref_date) AS mes,
       SUM(custo_sinistro) AS sinistro,
       SUM(premio_prorata) AS receita,
       SUM(custo_sinistro)
       / NULLIF(SUM(premio_prorata),0)
       AS sinistralidade
FROM fatos JOIN dims ...
GROUP BY 1, 2;
```

Saída: uma linha por (empresa × mês), com receita, sinistro e razão — base direta do Painel de Risco (Parte 3).

Data Quality: 74 testes automáticos, 9 tabelas



Domínio

20 testes

Valores dentro das listas aceitas (porte, UF, tipo, status)



Regras de negócio

16 testes

Cálculos financeiros: $\text{receita} = \text{valor/vida} \times \text{vidas}$; $\text{margem} = \text{receita} - \text{custo}$



Integridade

14 testes

FKs sem órfãos: cadeia empresa → contrato → beneficiário



Unicidade

10 testes

PKs sem duplicata (empresa_id, contrato_id, evento_id)



Volume

9 testes

Cada tabela com a quantidade esperada de registros



Completude

5 testes

Campos obrigatórios sem valores em branco

PASS / WARN / FAIL bloqueia o pipeline — dado ruim não chega ao relatório

Execução 1: 73 PASS · 1 WARN · 4 FAIL → duplicatas de empresa_id/contrato_id vindas da Silver propagaram até a Gold.

Execução 2: 73 PASS · 1 WARN · 0 FAIL  **Aprovado** após deduplicação defensiva na reconstrução das tabelas Gold.

De 7 arquivos crus a uma fonte única confiável

9

tabelas Gold

6 dimensões + 3 fatos, modelo Kimball

74

testes de QA

rodando a cada carga, 0 FAIL

~15,4 mil

registros tratados

1.558 vidas · 6.480 eventos

1

métrica-chave

sinistralidade pronta no BI

O que isso significa para o negócio



Uma versão oficial dos números

Dashboards, relatórios financeiros e KPIs passam a beber da mesma fonte — fim das divergências entre planilhas.



Confiança auditável

Cada carga é verificada automaticamente; um problema de dado é bloqueado antes de virar decisão errada.



Pronto para análise

A camada já resolve datas BR, categorias despadronizadas e duplicatas — o analista foca em pergunta de negócio, não em limpeza.

2

PARTE 2 · ANÁLISE & INSIGHTS DE NEGÓCIO

Onde o time deve atuar

Profundidade analítica e recomendações que o negócio consiga executar — usando a camada Gold construída na Parte 1.

Cinco consultas, cinco decisões

1

Planos mais vendidos (12m)

Ranking por nº de contratos e por vidas cobertas.

Decisão: % via window SUM() OVER() — volume ≠ cobertura.

2

Top empresas por prêmio (6m)

Receita mensal acumulada, RANK() p/ empates.

Decisão: prêmio recorrente, não valor único da apólice.

3

Performance de corretores (trim.)

Valor, contratos e vidas por corretor.

Decisão: normalizo por dias ativos — justo p/ recém-admitidos.

4

Contratos a expirar (30d)

Valor em risco = receita mensal perdida.

Decisão: janela 01–30/07/2025; bordas inclusivas.

5

Sinistralidade por empresa (12m)

Acumulada (custo/receita), não média das taxas.

Decisão: 🟠 >100% prejuízo · 🟡 >80% atenção.

O que as consultas revelaram

R\$ 405M

maior prêmio mensal

Empresa Q17 (Logística, CE) lidera o ranking de 6 meses

4 contratos

expiram em 30 dias

R\$ 516M em receita mensal em risco — priorizar retenção

Carla Almeida

corretora nº1 (Jr)


R\$ 2.633/dia ativo — normalização revela talento júnior



Sinistralidade (12m) — o alerta que muda a conversa comercial

- 15 empresas em prejuízo técnico (>100%) e 21 acima de 80% de sinistralidade no período.

Caso extremo — Empresa K37: 1.218% de sinistralidade, -R\$ 1,3M acumulado. Empre



Quem são nossos usuários — e onde atuar

CONCENTRAÇÃO (PARETO)

41,7%

do custo (R\$ 41,1M) vem de apenas 132 pessoas — o top 10%. Custo médio R\$ 311 mil/pessoa, 6,5× a média.

Perfil do high-cost claimant



Titular, masculino, 45+ anos: a faixa 45+ é 58% do grupo. 72% do seu custo é cirurgia (ticket R\$ 88,7 mil). Oncologia, Endocrinologia e Psiquiatria lideram.

Segmentação



Faixa 45+ = 55,8% do custo com só 34% das vidas. Coparticipação atual reduz custo só 5% — mecanismo pouco efetivo. Logística/Média tem o maior custo per-capita (R\$ 150 mil).

Padrões de utilização



Cirurgia + Internação = 96,6% do custo com 30% dos eventos. PS custa 5,5× uma consulta e tem uso não-urgente — 4 empresas com >15% de eventos em PS.

Rigor: base de 6.465 eventos / 1.316 beneficiários com sinistro; sinistralidade acumulada (não média de taxas); separo correlação de causa.

2 a 4 recomendações acionáveis e priorizadas

P1 Case management do Top 10%

Gestor de caso p/ 132 vidas; 2ª opinião antes de cirurgia eletiva; navegação p/ ambulatório.

Impacto: ~R\$ 6,2M/ano · **KPI:** custo per-capita do grupo

P2 Abordar as 5 empresas de maior prejuízo

T20, G07, U21, K37, E05 — reajuste técnico + copay efetivo + saúde corporativa 45+.

Impacto: ~R\$ 7,3M/ano · **KPI:** sinistralidade pós-ação

P3 Redirecionar PS → ambulatório

Telemedicina 24h nas 4 empresas com >15% de PS (E31, R18, A01, M13).

Impacto: ~R\$ 350K/ano · **KPI:** razão PS/consulta <10%

P4 Redesenhar coparticipação

Copay progressivo: 30% em cirurgia eletiva, 0% em prevenção (o atual só reduz 5%).

Impacto: ~R\$ 6,3M/ano · **KPI:** frequência cirúrgica eletiva

Além do pedido — curiosidade analítica



RISCO · ALTA

Seleção adversa confirmada

Vidas com <3 meses custam 57% mais (R\$ 56K vs 35,5K). Ação: reforçar carência p/ cirurgia eletiva + DPS na adesão.



ACHADO · ALTA

Funil PS → cirurgia

29% de quem usa PS escala p/ cirurgia/internação em 90 dias (R\$ 11,1M). Janela média de 48 dias p/ interceptar.



ANOMALIA · ALTA

Pico sazonal Jun/25

144 cirurgias (Z=2,25, 4x o início do período) = R\$ 10,4M num só mês. Ação: provisionar reserva 40% maior e negociar rede.



RISCO · ALTA

Preço sistêmico imprevisível

Mesma cirurgia+especialidade varia até 28x. Ação: tabela de referência com teto no P90 e pacotes fechados.

Também verificados: carteira diversificada (HHI 414, saudável) e corretores sem sinistralidade elevada (<4%) — riscos descartados com evidência.

Da análise ao dinheiro na mesa

POTENCIAL IDENTIFICADO

~R\$ 20M

por ano em margem recuperável, somando as 4 recomendações priorizadas.

Cada real ancorado em evidência da camada Gold — não em achismo.

Perguntas de negócio respondidas com dado

Onde está o custo?	132 vidas (10%) = 42% do gasto. O alvo ficou nominal e priorizável.
Quais clientes dão prejuízo?	15 empresas >100% de sinistralidade, com o valor exato do rombo de cada uma.
Que custo é evitável?	Funil PS→cirurgia (29%), seleção adversa (+57%) e pico sazonal (R\$ 10,4M) mapeados.
Onde o comercial atua já?	5 contratos a renovar e 5 empresas a reprecificar, ordenados por valor em risco.




3

PARTE 3 · DASHBOARD & STORYTELLING

Comunicando ao negócio

Comunicar para uma audiência de negócio — liderança comercial e de operações de saúde. Da evidência à decisão.

Quatro painéis para a liderança



Painel de risco — sinistralidade & expiração

Empresa	Sinistr.	Status
Empresa K37	1.218%	prejuízo
Empresa U21	417%	prejuízo
Empresa G07	330%	prejuízo
Empresa T20	194%	prejuízo


Esquema dos painéis. Nas próximas telas, o dashboard real construído no Databricks (AI/BI) sobre a camada Gold.

Análise Comercial — visão geral (Databricks AI/BI)

O que a liderança lê aqui

- Planos mais vendidos**
 Plano Flex 529 (Vitamed) lidera: 5 contratos, 1.400 vidas cobertas em 12 meses.
- Empresas por prêmio (6m)**
 Q17 (Logística/CE) no topo; ranking pronto para o comercial priorizar contas.
- Corretores normalizados**
 Carla Almeida (Jr) lidera por dia ativo — mérito visível mesmo com pouco tempo de casa.
- Contratos a expirar (30d)**
 R\$ 515,9M de receita mensal em risco em 4 contratos — alvo imediato de retenção.
- Sinistralidade por empresa**
 Semáforo 🟡 🟠 🟢 : 15 empresas em prejuízo, com I09 sinalizada como 'sem receita'.

🔗 Link: https://github.com/luanrossini/salutar_saude_analise/tree/main/dashboard



Sinistros Detalhado — visão por evento

Onde o custo se concentra



- 1

Cirurgia domina o custo
Poucos tipos de evento puxam o gasto; cirurgia isolada supera todos os demais somados.
- 2

Especialidades-alvo
Clínica Geral, Cardiologia e Cirurgia lideram o custo por especialidade (Top 15).
- 3

Custo por empresa x setor
Top 20 empresas coloridas por setor — identifica onde intervir por carteira.
- 4

Curva mensal ascendente
Custo de sinistros cresce ao longo do período — sinal para provisionamento e rede.

Link: https://github.com/luanrossini/salutar_saude_analise/tree/main/dashboard



Três conclusões e a recomendação de onde atuar

1

O custo é concentrado

132 beneficiários (10%) concentram 42% do custo — R\$ 41,1M. A alavanca de maior ROI é a gestão de casos desse grupo.

2

15 empresas estão em prejuízo

Sinistralidade acima de 100% pressiona a margem. As 5 maiores somam mais de R\$ 7M de prejuízo recuperável.

3

Há custo evitável mapeado

Funil PS→cirurgia (29% escalam), seleção adversa (+57%) e copay ineficaz (−5%) — todos com ação e KPI definidos.



ONDE ATUAR

Gestão dos casos dos 132 high-cost solicitantes + reprecificação das 5 empresas em maior prejuízo. Maior impacto de margem no menor prazo.

Impacto-alvo ~R\$ 13M/ano, medido por aumento da sinistralidade em 3 meses.

4

PARTE 4 · IA NO DIA A DIA

Uso de IA

Como uso ferramentas de IA para acelerar, elevar a qualidade e automatizar — decidindo o que delegar, validando resultados e cuidando de dados sensíveis.

Onde ajudou, onde eu validei



Onde a IA acelerou

- Padrão de Código (PySpark/SQL) e definição do pipeline.
- Rascunho da modelagem dimensional e do diagrama.
- Documentação, README e estrutura desta apresentação.
- Geração de dados de teste sintéticos para validar regras.



Onde errou / precisou de mim

- Regras de negócio (limiar, pró-rata).
- Alucinou colunas inexistentes.
- Janela de data e nulos exigiram revisão.
- Dados de saúde: nunca expostos a ferramentas externas.

Um prompt que considerei útil

"A partir deste dicionário de dados, gere os testes de qualidade (unicidade, integridade referencial, ranges) como asserções declarativas e liste as suposições que você fez."

Por quê: força a IA a explicitar premissas — eu valido em vez de confiar cego.



Ideia de automação

Perfilamento de qualidade dos dados a cada ingestão: um agente que roda os testes, resume anomalias e abre um alerta com a regra provável — reduzindo triagem manual de RAW.

FECHAMENTO

Os 7 entregáveis

1 Diagrama do modelo dimensional (1.1)

2 Código do pipeline RAW → Gold + notas de qualidade (Parte 1)

3 Consultas SQL da Parte 2.1 (comentadas)

4 Análise de insights (2.2) com evidências

5 Dashboard + narrativa executiva (Parte 3)

6 Relato de uso de IA (Parte 4)

7 README curto: como rodar + suposições

Do dado cru à recomendação de negócio.